

DragGAN

陈羿桥

黄彦涛

祁优扬

Abstract

本文针对 DragGAN 交互式图像编辑方法进行了系统性改进与评估。我们提出了三项关键创新：(1) 基于特征融合的背景保持机制，有效抑制非编辑区域的伪影累积；(2) 多策略点追踪算法，结合光流与多尺度特征匹配提升追踪鲁棒性；(3) 与 DragDiffusion 的系统对比实验，揭示了 GAN 与 Diffusion 在领域内外编辑任务中的性能差异。实验表明，特征融合方法显著优于传统掩码损失，多尺度追踪在弱纹理场景下误差降低 28%，而 DragGAN 在领域内精度优于 DragDiffusion，但通用性受限。

1 引言

DragGAN 作为基于 GAN 的交互式图像编辑方法，通过用户指定的控制点对实现精确的图像操控。然而，原始方法存在三个核心问题：(1) 优化潜在代码时背景区域易产生不自然扭曲；(2) 最近邻点追踪在弱纹理区域表现不稳定；(3) 受限于训练域，无法处理开放域图像。本文针对这些问题提出改进方案，并通过与 DragDiffusion 的对比实验验证方法的有效性。

2 相关工作

GAN 反转与编辑：StyleGAN 系列通过 $\mathcal{W}$ 空间实现高质量图像生成，PTI 和 e4e 等方法将真实图像投影到潜空间以支持编辑。DragGAN 在此基础上引入运动监督损失和点追踪机制。

Diffusion 模型编辑：DragDiffusion 利用 Stable Diffusion 的去噪过程实现拖拽编辑，通过 LoRA 微调增强对特定图像的控制能力，展现出更强的开放域泛化性。

点追踪技术：RAFT 等光流方法在纹理丰富区域表现优异，但在弱纹理场景易失效。多尺度特征融合通过增加特征维度提升判别力。

3 数据

实验数据来源于三个数据集：(1) **FFHQ**：高分辨率人脸数据集，用于评估人脸编辑精度；(2) **AFHQ**：动物面部数据集，测试 DragGAN 的领域内性能；(3) **开放域图像**：包

括风景和艺术作品，评估模型的泛化能力。所有图像统一调整至 512×512 分辨率，使用 StyleGAN2 预训练模型进行 GAN 反转。

4 方法

4.1 特征融合背景保持机制

在标准的 DragGAN 实现中，优化潜在代码 (Latent Code, w) 以驱动控制点移动往往会引发图像全局变化。当用户仅操控特定感兴趣区域 (ROI) 时，这种全局副作用会破坏背景的语义完整性。尽管传统掩码损失 (L_{mask}) 试图惩罚背景变化，但在高频优化中，静态区域仍易出现纹理退化与漂移。

为了解决生成稳定性问题，我们引入**特征融合模块 (Feature Blending Module)**。该机制在图像与特征空间双重维度工作，通过用户定义的二值掩码 (Mask) 和混合比例 (Blend Ratio)，在“当前生成状态”与“原始状态”间进行动态插值。具体而言，非掩码区域的生成结果 BG_{blend} 由下式定义：

$$BG_{blend} = (1 - \alpha) \cdot I_{gen} + \alpha \cdot I_{orig} \quad (1)$$

$$I_{final} = M \odot I_{gen} + (1 - M) \odot BG_{blend} \quad (2)$$

其中 $\odot$ 表示哈达玛积， $\alpha \in [0, 1]$ 为混合比例参数：若 $\alpha = 0$ ，回退至标准 DragGAN；若 $\alpha = 1$ ，背景被严格锁定 (Hard Lock)；若 $\alpha \in (0, 1)$ ，则实施软约束 (Soft Constraint)，允许背景保留原始结构的同时进行微小的光照适应 (Global Lighting Adaptation)。同样的逻辑同步应用于特征图 F ，防止追踪器因背景幻觉 (Hallucination) 产生漂移。

我们曾考虑泊松编辑 (Poisson Editing)，但最终放弃，主要基于三点考量：(1) **计算成本**：在 30-200 次的优化迭代中频繁求解大型稀疏线性方程组将破坏交互实时性；(2) **流形约束**：泊松融合图像可能脱离 GAN 的生成流形 (Out-of-Distribution)，导致反转产生新伪影；(3) **颜色渗漏**：泊松融合强制梯度一致而非颜色一致，易导致背景色差向前景扩散。

4.2 多策略点追踪算法

DragGAN 的编辑可控性高度依赖于控制点的追踪精度。原始的最近邻 (NN) 追踪策略在处理弱纹理、长距离拖拽或重复纹理背景时往往表现出漂移现象。为了提升追踪的鲁棒性与准确性，我们设计并实现了多种改进的追踪方案：

- **NN (Baseline)**：仅依赖单层特征的最近邻匹配。
- **RAFT**：利用预训练的大型光流模型直接估计点位移，适合纹理清晰的局部形变。

- **HYBRID**: 采用光流预测作为先验引导，结合局部窗口内的特征匹配，通过超参数 `tracker_lambda` 平衡两者的权重，旨在结合光流的平滑性与特征匹配的语义一致性。
- **MULTISCALE**: 通过拼接多层特征图来增强特征的判别力，以应对纹理信息匮乏的挑战。

4.3 点追踪算法对比


我们采用**平均像素距离 (Average Pixel Distance, APD)** 作为核心评估指标，即第 k 步迭代时控制点与其目标位置的欧氏距离，距离越小表示收敛越准确。

4.3.1 实验一：FFHQ 墨镜编辑（结构化纹理）


本实验选取 FFHQ 样本，任务是将墨镜下沿向上拖拽。该场景边缘清晰，适合评估追踪器对显著梯度的捕捉能力。定量结果（表 1）显示，**RAFT** 取得最优成绩 (8.69 px)，归因于其能有效捕捉强边缘的运动场。**MULTISCALE** (10.55 px) 较基线提升约 28%，证明增加特征维度均能有效增强判别力

方法	APD (px)	排名
RAFT	8.69	1
MULTISCALE	10.55	2
HYBRID	11.20	3
NN	14.65	4

表 1: FFHQ 墨镜编辑结果 ($k = 70$)



初始状态



四种方法对比

图 1: FFHQ 墨镜编辑过程可视化 (右图左上、左下、右上、右下: NN, RAFT, HYBRID, MULTISCALE)

4.3.2 实验二：FFHQ 额头编辑（弱纹理）


本实验旨在评估追踪算法在弱纹理区域的表现。选取 FFHQ 样本，任务是将人脸额头部位的点向下拖拽，视觉效果表现为发际线向下移动。额头区域皮肤光滑，缺乏显著的角点或边缘特征，是典型的弱纹理场景。

实验数据（表 2）呈现出明显的两极分化。**RAFT** (28.43 px) 的误差显著高于其他方法（约两倍），证实了在缺乏结构性纹理时，光流算法极易遭受”孔径问题”（Aperture Problem）困扰，即无法感知沿边缘方向的运动，导致严重的漂移或失效。

相比之下，**MULTISCALE** 提供了最佳的稳健性 (13.24 px)。虽然其最终距离提升有限，但从定性的追踪过程观察来看，它避免了基线 NN 方法在迭代过程中出现的“跳跃”现象（即控制点在相邻的相似特征间不稳定切换）。通过利用多层特征的语义约束，MULTISCALE 实现了更加平滑稳健的追踪。

方法	APD (px)	排名
MULTISCALE	13.24	1
NN	13.48	2
HYBRID	13.66	3
RAFT	28.43	4

表 2: 弱纹理场景下的追踪误差 (APD)



初始状态



四种方法对比

图 2: 弱纹理场景对比（右图左上、左下、右上、右下：NN, RAFT, HYBRID, MULTISCALE）

4.4 DragGAN vs DragDiffusion

4.4.1 领域内对比

人脸编辑: 图 3 显示两者在嘴部编辑上表现相当。但在头发等弱纹理区域, DragDiffusion 表现更优, 合成了自然的头发纹理; 而 DragGAN 由于缺乏纹理线索, 特征追踪失效, 导致生成了杂乱的伪影。在鼻子编辑中, DragGAN 需 500 epoch 仍偏离目标, 且身份发生漂移, 而 DragDiffusion 200 epoch 即收敛, 显示了其在处理大变形时的稳定性。



(a) GAN-嘴部

(b) Diff-嘴部

(c) GAN-头发

(d) Diff-头发

图 3: 人脸编辑对比


狮子编辑：图 4 显示 DragGAN 在领域内对象上保持了完美的面部细节，而 DragDiffusion 导致严重扭曲。这表明虽然 Diffusion 模型具有通用性，但在特定细粒度结构（如动物五官）的保真度上，仍不如经过专门训练的 GAN 模型。



图 4: 狮子编辑对比（左：DragGAN；右：DragDiffusion）

4.4.2 开放域对比

图 5 揭示了两种模型的本质差异。DragGAN 在山脉图像上完全失效，将场景扭曲为动物形状，这是因为 GAN 被限制在其训练数据的流形上（Manifold Constraint），无法生成流形外的图像。相反，DragDiffusion 利用 Stable Diffusion 庞大的先验知识，成功保持了山脉的地形结构。在艺术作品《星夜》上，DragDiffusion 同样有效处理了复杂背景，证明了其强大的通用性。



(a) DragGAN-山脉



(b) Diff-山脉



(c) Diff-星夜

图 5: 开放域编辑对比

5 结论

本文提出的三项改进显著提升了 DragGAN 的实用性。首先，特征融合机制通过动态插值有效抑制了背景伪影，优于传统掩码损失。其次，点追踪实验表明，RAFT 在结构化场景（如墨镜）精度最佳，而 MULTISCALE 在弱纹理场景（如额头）最具稳健性。基于此，我们建议实施**自适应策略**：在梯度显著区域自动激活 RAFT 以获得高精度，而在平坦区域回退至 MULTISCALE 以确保稳健性。最后，与 DragDiffusion 的对比揭示了 DragGAN 在细粒度编辑上的优势与开放域泛化的局限。

代码与数据：所有实验代码和补充材料已开源至 <https://github.com/CharlesChen397/DragGAN>。