

DragGAN: 基于特征融合与多策略追踪的交互式图像编辑

陈羿桥

黄彦涛

祁优扬

Abstract

本文针对 DragGAN 交互式图像编辑方法进行了系统性改进与评估。我们提出了三项关键创新：(1) 基于特征融合的背景保持机制，有效抑制非编辑区域的伪影累积；(2) 多策略点追踪算法，结合光流与多尺度特征匹配提升追踪鲁棒性；(3) 与 DragDiffusion 的系统对比实验，揭示了 GAN 与 Diffusion 在领域内外编辑任务中的性能差异。实验表明，特征融合方法显著优于传统掩码损失，多尺度追踪在结构化场景下误差降低 28%，而 DragGAN 在领域内精度优于 DragDiffusion，但通用性受限。

1 引言

DragGAN [1] 作为基于 GAN 的交互式图像编辑方法，通过用户指定的控制点对实现精确的图像操控。然而，原始方法存在三个核心问题：(1) 优化潜在代码时背景区域易产生不自然扭曲；(2) 最近邻点追踪在弱纹理区域表现不稳定；(3) 受限于训练域，无法处理开放域图像。本文针对这些问题提出改进方案，并通过与 DragDiffusion 的对比实验验证方法的有效性。

2 相关工作

GAN 反转与编辑：StyleGAN 系列 [4] 通过 $\mathcal{W}$ 空间实现高质量图像生成，PTI 和 e4e 等方法将真实图像投影到潜空间以支持编辑。DragGAN 在此基础上引入运动监督损失和点追踪机制。

Diffusion 模型编辑：DragDiffusion [2] 利用 Stable Diffusion 的去噪过程实现拖拽编辑，通过 LoRA 微调增强对特定图像的控制能力，展现出更强的开放域泛化性。

点追踪技术：RAFT [3] 等光流方法在纹理丰富区域表现优异，但在弱纹理场景易失效。多尺度特征融合通过增加特征维度提升判别力。

3 数据

实验数据来源于三个数据集：(1) **FFHQ**: 高分辨率人脸数据集，用于评估人脸编辑精度；(2) **AFHQ**: 动物面部数据集，测试 DragGAN 的领域内性能；(3) **开放域图像**: 包括风景和艺术作品，评估模型的泛化能力。所有图像统一调整至 512×512 分辨率，使用 StyleGAN2 预训练模型进行 GAN 反转。

4 方法

4.1 DragGAN 核心机制回顾

DragGAN 通过在生成的图像流形上优化潜在代码 w 来实现图像变形，其过程包含两个交替进行的子步骤：

- **运动监督 (Motion Supervision)**: 驱动控制点 p_i 向目标点 t_i 移动。损失函数定义为：

$$\mathcal{L} = \sum_{i=0}^n \sum_{q_i \in \Omega_1(p_i, r_1)} \|F(q_i) - F(q_i + d_i)\|_1 + \lambda \| (F - F_0) \cdot (1 - M) \|_1 \quad (1)$$

其中 Ω_1 是控制点周围的邻域， d_i 是归一化的位移向量。第一项强制特征图在控制点周围发生位移，第二项通过二值掩码 M 保持非编辑区域（背景）不变。

- **点追踪 (Point Tracking)**: 更新控制点位置以跟踪图像上的物体。基线方法通过在特征图 F 上进行最近邻搜索：

$$p_i \leftarrow \arg \min_{q \in \Omega_2(p_i, r_2)} \|F(q) - f_i\|_2 \quad (2)$$

其中 f_i 是控制点的初始特征值。

4.2 特征融合背景保持机制

在标准的 DragGAN 实现中，优化潜在代码往往会引发图像全局变化。尽管传统掩码损失试图惩罚背景变化，但在高频优化中，静态区域仍易出现纹理退化与漂移。

为了解决生成稳定性问题，我们引入**特征融合模块 (Feature Blending Module)**。该机制在图像与特征空间双重维度工作，通过用户定义的二值掩码 M 和混合比例 α ，在“当前生成状态”与“原始状态”间进行动态插值。具体而言，非掩码区域的生成结果 BG_{blend} 由下式定义：

$$BG_{blend} = (1 - \alpha) \cdot I_{gen} + \alpha \cdot I_{orig} \quad (3)$$

$$I_{final} = M \odot I_{gen} + (1 - M) \odot BG_{blend} \quad (4)$$

其中 $\odot$ 表示哈达玛积， $\alpha \in [0, 1]$ 为混合比例参数：若 $\alpha = 0$ ，回退至标准 DragGAN；若 $\alpha = 1$ ，背景被严格锁定 (Hard Lock)；若 $\alpha \in (0, 1)$ ，则实施软约束 (Soft Constraint)。同样的逻辑同步应用于特征图 F ，防止追踪器因背景幻觉 (Hallucination) 产生漂移。

4.3 多策略点追踪算法

原始的最近邻 (NN) 追踪策略在处理弱纹理、长距离拖拽或重复纹理背景时往往表现出漂移现象。为了提升追踪的鲁棒性，我们设计了多种改进方案：

- **RAFT**: 利用预训练的 RAFT 光流模型直接估计点位移，适合纹理清晰的局部形变。
- **HYBRID**: 结合 RAFT 光流与多尺度特征匹配。以光流预测为中心构建搜索窗口，在其中进行特征匹配，通过代价函数 $C = \|F - F_{ref}\|_2 + \lambda \cdot d_{flow}$ 平衡特征相似性与光流一致性。
- **MULTISCALE**: 通过拼接 StyleGAN 的第 3, 5, 7, 9 层特征来增强特征的判别力，仅使用最近邻匹配（无光流），以应对纹理信息匮乏的挑战。

4.4 代码实现细节分析

基于官方代码库的分析，我们确认了核心机制的具体实现方式，这对复现效果至关重要。

运动监督中的梯度截断 (Stop Gradient) 在计算运动监督损失时，代码采用了梯度截断策略。核心思想是：将源位置 q 的特征值 $F(q)$ 视为固定的目标 (Ground Truth)，优化 w 使目标位置 $q + d$ 的特征值 $F(q + d)$ 向其逼近。代码实现为：

$$\mathcal{L}_{motion} = \|F(q).\text{detach}() - F(q + d)\|_1 \quad (5)$$

其中 `.detach()` 阻断了梯度向 $F(q)$ 的回传，确保优化器仅更新 w 以改变 $F(q + d)$ 处的特征值。这一设计使图像内容从 q ”流向” $q + d$ ，实现拖拽效果。若移除此操作，优化器可能同时改变 $F(q)$ ，导致图像崩塌。

多尺度特征选择 在多尺度追踪 (MULTISCALE) 的实现中，我们选择 StyleGAN2 生成器的第 3, 5, 7, 9 层特征进行拼接（默认运动监督使用第 5 层）。这些层对应不同的分辨率和语义层级：低层特征（如第 3 层）提供精细的边缘纹理信息，高层特征（如第 9 层）提供抽象的语义形状约束。通过 `torch.cat` 在通道维度融合，构建判别力更强的特征描述符 F_{fused} ，有效提升弱纹理区域的追踪稳定性。

5 实验

5.1 基础复现与定性分析

在进行改进之前，我们首先基于官方代码库在 FFHQ（人脸）、AFHQ（猫狗狮子）及 LSUN（汽车）数据集上进行了基础功能复现。实验结果（如图 4 左侧及图 3 (a/c) 所示）表明：

- **精确控制**: 模型能够响应细微的用户交互，如精确开合嘴部和调整视线方向。

- **长距离拖拽**：对于狮子鼻子的长距离移动，模型成功生成了随视角偏转的侧脸结构，验证了 GAN 潜在空间良好的连续性。
- **局限性**：在复现过程中我们也观察到，对于旋转角度过大（超过 45° ）的操作，纹理容易出现伪影，且无纹理区域（如皮肤）的控制点容易发生漂移，这进一步证实了我们后续改进工作的必要性。

5.2 点追踪算法对比


我们采用**平均像素距离 (APD)** 作为评估指标，即第 k 步迭代时控制点与其目标位置的欧氏距离，距离越小表示收敛越准确。

5.2.1 结构化纹理场景 (FFHQ 墨镜)


本实验任务是将墨镜下沿向上拖拽。定量结果（表 1）显示，**RAFT** 取得最优成绩（8.69 px），归因于其能有效捕捉强边缘的运动场。**MULTISCALE**（10.55 px）较基线提升约 28%，证明增加特征维度能有效增强判别力。

方法	APD (px)	排名
RAFT	8.69	1
MULTISCALE	10.55	2
HYBRID	11.20	3
NN	14.65	4

表 1: FFHQ 墨镜编辑结果 ($k = 70$)



初始状态



四种方法对比


图 1: FFHQ 墨镜编辑过程可视化（右图左上、左下、右上、右下: NN, RAFT, HYBRID, MULTISCALE）

5.2.2 弱纹理场景 (FFHQ 额头)


本实验任务是将人脸额头部位的点向下拖拽。实验数据（表 2）呈现出明显的两极分化。**RAFT** (28.43 px) 的误差显著高于其他方法，证实了光流算法在弱纹理区域易遭受“孔径问题”困扰。相比之下，**MULTISCALE** 提供了最佳的稳健性（13.24 px），避免了基线 NN 方法在迭代过程中的“跳跃”现象。

方法	APD (px)	排名
MULTISCALE	13.24	1
NN	13.48	2
HYBRID	13.66	3
RAFT	28.43	4

表 2: 弱纹理场景下的追踪误差 (APD)



初始状态



四种方法对比

图 2: 弱纹理场景对比 (右图左上、左下、右上、右下: NN, RAFT, HYBRID, MULTISCALE)

5.3 DragGAN vs DragDiffusion

5.3.1 领域内对比 (FFHQ & AFHQ)

人脸编辑: 图 3 显示两者在嘴部编辑上表现相当。但在头发等复杂纹理区域, DragDiffusion 表现更优。然而在鼻子编辑等改变身份的微调中, DragDiffusion 200 epoch 即收敛, 显示了更好的稳定性。

狮子编辑: 图 4 显示 DragGAN 在领域内对象上保持了完美的面部细节, 而 DragDiffusion 导致严重扭曲。这表明虽然 Diffusion 模型具有通用性, 但在特定细粒度结构 (如动物五官) 的保真度上, 仍不如经过专门训练的 GAN 模型。



图 3: 人脸编辑对比



图 4: 狮子编辑对比 (左: DragGAN; 右: DragDiffusion)

5.3.2 开放域对比

图 5 揭示了两种模型的本质差异。DragGAN 在山脉图像上完全失效，将场景扭曲为动物形状，因为 GAN 被限制在其训练数据的流形上。相反，DragDiffusion 利用 Stable Diffusion 庞大的先验知识，成功保持了山脉的地形结构。在艺术作品《星夜》上，DragDiffusion 同样有效处理了复杂背景。



图 5: 开放域编辑对比

6 结论

本文提出的三项改进显著提升了 DragGAN 的实用性。首先，特征融合机制通过动态插值有效抑制了背景伪影。其次，点追踪实验表明，RAFT 在结构化场景精度最佳，而 MULTISCALE 在弱纹理场景最具稳健性。建议实施自适应策略：在梯度显著区域自动激活 RAFT，而在平坦区域回退至 MULTISCALE。最后，与 DragDiffusion 的对比揭示了 DragGAN 在细粒度编辑上的优势与开放域泛化的局限。

代码与数据：实验代码已开源至 <https://github.com/CharlesChen397/DragGAN>。

References

- [1] Pan, X., Tewari, A., Leimkühler, T., Liu, L., Meka, A., & Theobalt, C. (2023). Drag Your GAN: Interactive Point-based Manipulation on the Generative Image Manifold. *SIGGRAPH*.
- [2] Shi, Y., Xue, C., Pan, J., Zhang, W., Tan, V. Y., & Bai, S. (2024). DragDiffusion: Harnessing Diffusion Models for Interactive Point-based Image Editing. *ICLR*.
- [3] Teed, Z., & Deng, J. (2020). RAFT: Recurrent All-Pairs Field Transforms for Optical Flow. *ECCV*.

- [4] Karras, T., Laine, S., Aittala, M., Hellsten, J., Lehtinen, J., & Aila, T. (2020). Analyzing and Improving the Image Quality of StyleGAN. *CVPR*.